

Python Twitter 情緒分析

川普國會山莊事件衝擊

以 2021 年 1 月 6 日國會暴動為例

Twitter 情緒分析專案解說

製作人 B12204033 施邵

報告大綱

- 1 研究背景
- 2 資料與方法
- 3 程式碼講解
- 4 分析結果

研究背景與核心問題

- 2021 年 1 月 6 日，美國國會山莊發生暴動，社群平台成為政治動員與情緒擴散的重要場域。
- 川普在事件前後的公開發言與推文，是否與 Twitter 上的討論量與情緒波動呈現明顯關聯，是本專題的核心問題。
- 本研究以 Python 建立完整分析流程，結合情緒分析、時間序列分群與視覺化圖表，觀察事件相關討論的情緒變化。
- 本專題目標不是宣稱單一貼文直接造成暴動，而是評估政治人物訊號是否具有推波助瀾的觀察證據。

研究假設與分析主軸

研究假設

當討論內容聚焦於川普、國會山莊、Pence 與 riot 等事件關鍵詞時，Twitter 討論將呈現較高的負向情緒比例，並在關鍵發文時點附近出現明顯放大量。

- 分析主體：2021-01-06 當日 Twitter 討論資料。
- 分析方法：VADER 情緒分析 + 15 分鐘時間窗聚合。
- 觀察重點：討論量、負向比例、正負情緒差距、關鍵詞分布。
- 論述方向：以資料支持「情緒確實受到事件與關鍵政治訊號牽動」。

事件時間脈絡

時間（美東）	事件重點
12:00 p.m.	川普在華府集會發言，強調不接受敗選，要求支持者施壓國會。
2:24 p.m.	川普發文批評 Mike Pence，稱其沒有勇氣採取行動。
2:38 p.m.	川普發文呼籲支持國會警察並要求群眾 stay peaceful。
4:17 p.m.	川普發布影片，稱支持者是 very special，並要求 go home in peace。
6:01 p.m.	川普再發文，表示 remember this day forever。

資料來源：NPR/CapRadio 對 2021-01-06 國會山莊事件時間線整理。

資料來源與資料限制

資料概況

- 原始資料筆數：82,309
- 有效分析筆數：82,035
- 分析日期：2021-01-06
- 主要欄位：tweet_id、text、query、created_at

研究限制

- 此資料集為混合議題資料，不是川普官方帳號推文全集。
- 因此本研究採取「事件關鍵詞子集合」策略，聚焦與國會山莊事件高度相關的討論。
- 結論應解讀為高度關聯，而非單一貼文的直接因果證明。

為何不能直接使用 Twitter API

- 直接依賴 Twitter 或 X Developer API 進行大量歷史資料補齊，會受到 endpoint rate limits 限制。
- 官方文件明確指出，每個 endpoint 都有獨立的請求上限，超出後會回傳 429，需等待視窗重設。
- 對於已刪除、受保護或遭停權內容，官方 API 的可近性也有限。
- 因此本專題不以線上逐筆查詢建立時間戳，而改採 TweetedAt 所採用的 Snowflake 逆向工程方式，由 tweet ID 還原時間。

來源：X API Rate Limits 文件；TweetedAt README。

Snowflake 逆向工程的角色

核心概念

Twitter Snowflake ID 是一種 64-bit、近似依時間排序的識別碼，包含 timestamp、worker number 與 sequence number。

- Twitter 於 2010 年公開說明 Snowflake 的設計，強調其 ID 具備 roughly sortable 的時間特性。
- TweetedAt 將這個機制應用於時間還原，從 tweet ID 反推出建立時間。
- 本專題沿用這個思路，在無法逐筆調用 API 的前提下，補齊 created_at 欄位，才能進行時間序列分析。
- 因此，Snowflake 是本專題能夠成立的資料工程關鍵步驟。

事件子集合定義


關鍵詞篩選

以 `trump`、`capitol`、`congress`、`riot`、`insurrection`、`pence` 建立事件子集合。

子集合結果

- 子集合筆數：5,604
 - 佔整體資料：6.83%
 - 平均情緒分數：-0.1423
 - 討論量峰值：20:15 UTC，3,136 則
- 這個子集合不是完美因果樣本，但可以有效收斂到與川普及國會山莊事件高度相關的社群討論。
 - 後續圖表與結論，皆以此事件子集合為主軸。

分析流程總覽



VADER 情緒分析設計

- VADER (Valence Aware Dictionary and sEntiment Reasoner) 適合短文字、社群貼文與帶有情緒語氣的句子。
- 每則推文會得到一個 compound score，再依門檻分為 Positive、Neutral、Negative。
- 本專題優點在於流程穩定、可重跑、速度快，適合大量短文本做基礎情緒量化。
- 對政治諷刺、隱喻或雙關語仍有侷限，因此需要搭配時間脈絡與關鍵詞結果共同解讀。

程式碼一：資料載入與去重

```
1 def load_data(file_path=None):
2     path = Path(file_path) if file_path else resolve_default_input_file()
3     df = pd.read_csv(path)
4     prepared = df.copy()
5     prepared["text"] = prepared["text"].astype(str)
6     prepared["created_at"] = pd.to_datetime(
7         prepared["created_at"], errors="coerce", utc=True
8     )
9     prepared = prepared.dropna(subset=["created_at", "text"]).copy()
10    prepared = prepared.drop_duplicates(subset=["tweet_id"])
11    return prepared.sort_values("created_at").reset_index(drop=True)
```

- 先統一欄位格式，再刪除缺值與重複 tweet。
- 這一步確保時間排序與後續聚合結果一致。

程式碼二：事件子集合抽取

```
1 def filter_event_subset(df, keywords=EVENT_KEYWORDS):  
2     pattern = "|".join(keywords)  
3     mask = df["text"].astype(str).str.contains(  
4         pattern, case=False, na=False, regex=True  
5     )  
6     subset = df.loc[mask].copy()  
7     return subset.sort_values("created_at").reset_index(drop=True)
```


- 以事件關鍵詞建立與國會山莊事件高度相關的討論樣本。
- 這是本研究從混合議題資料集中萃取有效政治事件訊號的關鍵步驟。

程式碼三：情緒評分與時間聚合


```
1 time_df = compute_time_sentiment(event_subset_df, freq="15min", min_tweets=1)
2 distribution_df = compute_sentiment_distribution(event_subset_df)
3 comparison_df = compute_sentiment_comparison(scored_df, event_subset_df)
4
5 event_timeline_figure_path = plot_event_timeline(
6     time_df=event_time_df,
7     output_path=figure_dir / "capitol_event_timeline.png",
8     title="Jan. 6 Capitol Event Subset: Sentiment and Volume Over Time",
9     event_markers=event_markers,
10 )
```

- 以 15 分鐘為單位觀察情緒比例與討論量變化。
- 再把關鍵發文時點標在圖上，對照事件節奏。

整體資料情緒儀表板




事件子集合與整體資料比較




- 整體資料負向比例為 33.34%，但事件子集合提高到 54.12%。

事件時間軸：討論量與情緒同步觀察



事件關鍵詞圖



- 負向詞群集中於 trump、capitol、lost、congress、senate。
- 正向詞群雖然存在，但多與支持者立場、選舉敘事或國家認同相關。

結果解讀

主要發現

在 2021 年 1 月 6 日的事件相關子集合中，Twitter 討論呈現更高比例的負向情緒，且在川普關鍵訊號與事件升高時段附近出現顯著討論量峰值。

- 事件子集合平均情緒分數為 -0.1423，顯示整體情緒偏負面。
- 討論量峰值與事件升溫時間接近，說明政治人物訊號與社群反應具有同步放大關係。
- 因為負向比例大幅高於整體資料基準，可合理推論事件相關內容確實對社群情緒造成衝擊。

研究限制與方法邊界

- 本資料集不是川普官方帳號推文全量資料，因此不宜宣稱嚴格因果。
- 事件子集合使用關鍵詞篩選，仍可能混入評論、轉述與媒體報導內容。
- VADER 對政治諷刺與上下文依賴語句的判斷仍有誤差。
- 因此本研究最適合的表述是：川普相關政治訊號與社群情緒升高呈現明顯關聯，具有推波助瀾的觀察證據。

結論

- 1 本專題成功以 Python 建立可重跑的 Twitter 情緒分析流程，完成資料整理、Snowflake 時間還原、VADER 評分與圖表輸出。
- 2 在 1 月 6 日國會山莊事件相關子集合中，負向情緒比例由整體資料的 33.34% 上升到 54.12%。
- 3 事件相關討論在關鍵發文時段附近出現大規模放量，支持「政治人物訊號會強化社群情緒波動」的研究判斷。
- 4 綜合本次資料，本專題結論傾向認為：川普相關發文與國會山莊事件討論之間，存在明顯的情緒放大效果。

參考來源

- X Engineering Blog, *Announcing Snowflake*, 2010.
- X Developer Platform, *X API Rate Limits*.
- TweetedAt README and TimestampEstimator documentation.
- NPR / CapRadio, *A timeline of the Jan. 6 Capitol attack—including when and how Trump responded*.
- 本專題自建分析結果: `outputs/reports/` 與 `outputs/figures/`。

Thank You

Q&A